Tabel *Baseline* (SOTA)

Framework Adaptive Embedding Selection Efisiensi Semantic Retrieval untuk Dokumen Pemerintahan
Sufyaldy : 250534921342

No	Paper Utama	Klasifikasi Jurnal / Prosedur	Pendekatan Utama Paper (SOTA)	Urgensi Menjadi Baseline	Posisi & Value Proposition Riset (Mengisi Gap)	Link Paper
1	**Embedding-Informed Adaptive Retrieval-Augmented Generation** (COLING, Jan 2025)	ACL Anthology / Top Conference	Mengeksplorasi token embedding dari *layer* awal untuk mendeteksi kerumitan informasi sebelum memutuskan melakukan *retrieval* spenuh.	**Baseline untuk Arsitektur Efisiensi.** Memvalidasi tren akademik bahwa embedding bisa berfungsi sebagai 'kompas' penghemat komputasi.	Fokus arsitektur ini pada **karakteristik unik tata kelola dokumen pemerintahan** yang memiliki keterbatasan resource dan regulasi privasi lokal.	https://aclanthology.org/2025.coling-main.94.pdf

2	**A Dynamic-Selection-Based, Retrieval-Augmented Generation Framework** (MDPI, 2025)	Scopus Q2 / MDPI Electronics	Menggunakan mekanisme *Dynamic Selection* pada level dokumen/konteks masukan untuk meminimalkan biaya API dan *resource*.	**Baseline untuk Desain Sistem (RQ1).** Memberikan bukti kuat bahwa skema seleksi dinamis sukses memotong biaya komputasi.	Paper ini menyeleksi dokumen mentah, framework menyeleksi **langsung pada level ekstraksi fitur/vektor embedding** sebelum komputasi retrieval besar terjadi.	https://www.mdpi.com/2079-9292/14/4/659/pdf?version=1739517237
3	**Matryoshka Representation Learning** (Kusupati et al., NeurIPS)	**Top-Tier / Scopus Q1** *(Flagship AI Conference)*	**Paper Pionir:** Melatih model agar *embedding* memiliki sifat bersarang (seperti boneka Matryoshka); dimensi kecil menyimpan informasi esensial dari dimensi besar.	**Fondasi Teoretis Utama.** Menjadi basis ilmiah mengapa sebuah vektor *embedding* bisa dipotong/dipilih dimensinya secara adaptif saat *runtime* tanpa perlu *retraining*.	MRL menyediakan struktur vektor yang fleksibel. Riset Anda berfokus pada **mekanisme pengambil keputusan (*selection mechanism*)** di tingkat sistem untuk menentukan kapan harus memakai struktur MRL tingkat rendah atau tinggi.	https://dl.acm.org/doi/proceedings/10.5555/3600270

4	**Domain-Specific RAG with Adaptive Embedding & Knowledge Distillation** (MDPI, Des 2025)	Scopus Q2 / MDPI Processes	Menyesuaikan embedding adaptif dikombinasikan dengan *re-ranking* ringan untuk penyelarasan semantik di bidang industri spesifik.	**Baseline untuk Validasi Domain.** Menjadi pembanding yang setara untuk pengujian embedding adaptif pada wilayah data yang tidak umum.	Riset berfokus pada **Domain Pemerintahan (*e-government*)** yang memiliki bahasa birokrasi formal dan memerlukan akurasi hukum yang ketat.	https://www.mdpi.com/2227-9717/14/1/99/pdf?version=1767075212
5	**Scaling Laws for Embedding Dimension in Information Retrieval** (Feb 2026)	arXiv / Neural Retrieval	Memberikan pembuktian matematis mengenai batas optimal (*diminishing returns*) ukuran dimensi embedding vs biaya inferensi komputasi.	**Landasan Teoretis (Justifikasi Utama).** Membuktikan secara matematis bahwa memakai model besar secara terus-menerus adalah pemborosan komputasi.	Riset merupakan **solusi praktis dari hukum ini**: menggunakan *scaling laws* tersebut sebagai basis aturan/klasifikasi kapan sistem harus mengaktifkan embedding ringan atau berat.	https://arxiv.org/abs/2602.05062